Estrategia y el Marco Ético

Diccionario de Datos

Campo	Descripción	Tipo de Dato	Ejemplo
InvoiceNo	Identificador único de la factura.	VARCHAR(15)	784256
Description	Nombre o descripción detallada del artículo.	VARCHAR(100)	White Mug
Quantity	Unidades vendidas por transacción.	INT	6
InvoiceDate	Estampa de tiempo (fecha y hora) de la transacción.	DATETIME	2010/10/01 08:26
UnitPrice	Precio unitario del producto en USD.	DECIMAL(6,2)	2.55
CustomerID	Identificador único del cliente.	INT	17850
Country	País de residencia del cliente.	VARCHAR(50)	United Kingdom
Discount	Tasa de descuento aplicada (0.00 a 1.00).	DECIMAL(3,2)	0.47
PaymentMethod	Método de pago utilizado.	VARCHAR(50)	Bank Transfer
ShippingCost	Costo logístico del envío.	DECIMAL(5,2)	10.79
Category	Tipo de producto adquirido.	VARCHAR(50)	Electronics
SalesChannel	Canal de venta (Online/Físico).	ENUM('Online', 'In-store')	In-store
ReturnStatus	Estado de devolución del pedido.	ENUM('Returned', 'Not Returned')	Not Returned
ShipmentProvider	Empresa encargada del envío del pedido.	VARCHAR(50)	UPS
WarehouseLocation	Ubicación física del almacén de origen.	VARCHAR(100)	Berlin
OrderPriority	Nivel de prioridad del envío.	ENUM('Low', 'Medium', 'High')	Medium

Linaje de Datos

Origen

- Archivo ‘online_retail_dataset.csv'

Procesamiento Inicial: Limpieza en Excel

- Filtrado de registros que contenían Quantity y UnitPrice con valores negativos o cero.
- Remoción de registros sin CustomerID ni WarehouseLocation.
- Creación del archivo Ventas_Limpias.csv

Almacenamiento: Carga en MySQL

- Creación de la base de datos que almacenará los registros.
- Carga masiva del dataset.
- Estandarización de formatos.
- Creación y exportación de la View con el campo calculado *NetRevenue*.

Transformación: Elaboración de Métricas

- Indicadores Generales (Ingresos Totales, Volumen de Pedidos y Ticket Promedio)
- Consolidación de ventas totales y volumen de pedido agrupados por *Category* y *Country*
- Extracción del mes y año de *InvoiceDate* para identificar tendencias estacionales.
- Determinación del costo de envío promedio por *WarehouseLocation* y *ShipmentProvider*.

Visulización: Construcción del Dashboard

- Resumen de Alto Nivel (Cards)
- Distribución Por Productos
- Análisis Temporal
- Análisis Geográfico
- Eficacia Logística

Matriz de Calidad

Campo	Dimensión de Calidad	Regla de Negocio	Limpieza Realizada
Quantity	**Validez / Consistencia**	Debe ser un valor entero mayor a 0.	Se borraron registros menores a 0.
UnitPrice	**Validez**	El precio debe ser un valor positivo.	Se borraron registros con precios negativos o en 0.
CustomerID	**Completitud**	Identificador obligatorio para análisis de comportamiento de clientes.	Se descartaron registros nulos para evitar sesgo en métricas de lealtad.
WarehouseLocation	**Completitud**	Requerido para el análisis de logística y distribución geográfica.	Se descartaron registros vacíos para asegurar integridad en reportes regionales.
General	**Unicidad**	Sólo deben existir transacciones únicas.	Eliminación de registros duplicados.

Marco Ético

Privacidad	Aunque manejamos `CustomerID`, no existen nombres, correos o direcciones físicas que permitan identificar a una persona real (cumplimiento con principios de GDPR/LPDP).
Transparencia	Todas las exclusiones de datos están justificadas por falta de integridad, asegurando que los resultados no se vean afectados.
Sesgo	Los datos no se pueden extrapolar al resto de regiones, por consiguiente toda tendencia que se pueda inferir es netamente a los países y ciudades propios del dataset.

Gestión Predictiva

Definición de Roles

Gerencia de Ventas	Define las prioridades y el valor de negocio de los KPI's.
SCRUM Master	Asegura el cumplimiento de las etapas del proyecto.
Equipo de Datos	Responsables de la ejecución técnica en SQL y visualización de datos en Tableau

Distribución de Labores

Área	Responsabilidad en el Proyecto	Entregable Principal
Gobernanza y Cumplimiento de Datos	Definir el Diccionario de Datos, el Marco Ético y las reglas de la Matriz de Calidad.	Catálogo de Datos y Políticas de Privacidad.
Ingeniería de Datos	Crear la infraestructura en SQL, automatizar la carga y los Quality Gates.	Base de Datos robusta y Scripts de Limpieza.
Analítica de Datos	Ejecutar el análisis modular, creación y optimización de consultas.	Scripts de Análisis y Reportes de Hallazgos.
Inteligencia de Negocios (BI)	Diseñar el Storytelling y el Dashboard en Tableau.	Tablero de Control Interactivo (Dashboard).
Observabilidad de Datos	Configurar el monitoreo, las alertas de salud y detectar el Data Drift.	Dashboard de Salud y Alertas de Monitoreo.

Cronograma SCRUM

Sprint 1: Fundación y Gobernanza

- **Objetivo:** Establecer el Diccionario de Datos y Marco Ético
- **Entregable:** Documento de Gobernanza y Matriz de Calidad

Sprint 2: DataOps e Infraestructura

- **Objetivo:** Implementar el esquema SQL y realizar la carga masiva del dataset (43,769 registros).
- **Entregable:** Base de Datos activa y ejecutar las Pruebas de Calidad (0 errores).

Sprint 3: Analítica

- **Objetivo:** Desarrollar la lógica de negocio mediante consultas modulares.
- **Entregable:** Campo calculado del Ingreso Neto y agrupación por categorías.

Sprint 4: BI y Observabilidad

- **Objetivo:** Crear la capa visual en Tableau y el protocolo de monitoreo.
- **Review Final:** Dashboard final interactivo y scripts de alertas de salud.

Criterio de Etapa Culminada (DoD)

- **Precisión:** Los totales de la base de datos coinciden con el dataset original.
- **Legibilidad:** Código SQL indentado, con alias claros y comentarios explicativos.
- **Validación:** Las Pruebas de Calidad fueron un éxito, la carga de datos no tuvo errores.
- **Visualización:** Los gráficos del Dashboard son concisos y contienen filtros para una mayor granularidad en el análisis.

Infraestructura Robusta (DataOps)

Esquema de Datos

Preparación del Entorno

```sql
CREATE DATABASE IF NOT EXISTS online_retail_dataset;

CREATE TABLE IF NOT EXISTS online_retail_dataset.sales (
  InvoiceNo VARCHAR(15) NOT NULL,
  Description VARCHAR(100),
  Quantity INT NOT NULL CHECK(Quantity > 0),
  InvoiceDate VARCHAR(50) NOT NULL,
  UnitPrice DECIMAL(6, 2) NOT NULL CHECK(UnitPrice > 0),
  CustomerID INT UNSIGNED,
  Country VARCHAR(50),
  Discount DECIMAL(3, 2) DEFAULT 0.00,
  PaymentMethod VARCHAR(50),
  ShippingCost DECIMAL(5, 2) DEFAULT 0.00,
  Category VARCHAR(50),
  SalesChannel ENUM('Online', 'In-store') NOT NULL,
  ReturnStatus ENUM('Returned', 'Not Returned') DEFAULT 'Not Returned',
  ShipmentProvider VARCHAR(50),
  WarehouseLocation VARCHAR(100),
  OrderPriority ENUM('Low', 'Medium', 'High') DEFAULT 'Low',
  PRIMARY KEY (InvoiceNo, Description),
  INDEX idx_customer (CustomerID),
  INDEX idx_invoice_date (InvoiceDate)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4;
```

Proceso de Carga

```
SET GLOBAL local_infile = 1;

LOAD DATA LOCAL INFILE '...\\Uploads\\Ventas_Limpias.csv'
INTO TABLE sales
CHARACTER SET utf8mb4
FIELDS TERMINATED BY ','
ENCLOSED BY '"'
LINES TERMINATED BY '\n'
IGNORE 1 ROWS

( InvoiceNo,
  StockCode,
  Description,
  Quantity,
  @var_InvoiceDate,
  UnitPrice,
  CustomerID,
  Country,
  Discount,
  PaymentMethod,
  ShippingCost,
  Category,
  SalesChannel,
  ReturnStatus,
  ShipmentProvider,
  WarehouseLocation,
  OrderPriority
)
SET InvoiceDate = STR_TO_DATE(@var_InvoiceDate, '%d/%m/%Y %H:%i');

ALTER TABLE sales
MODIFY column InvoiceDate DATETIME;
```

Pruebas de Calidad

1.- Prueba de Integridad de Registros

Confirmar que, tras la carga, no existan facturas o clientes sin ID.

```
SELECT 'Error: Nulos encontrados' AS Status, COUNT(*) AS Cantidad_Errores
FROM sales
WHERE InvoiceNo IS NULL OR CustomerID IS NULL;
```

- Resultado esperado: 0 registros.

2.- Prueba de Lógica de Negocio

Asegurar que no se "colaron" valores negativos que distorsionen los cálculos.

```
SELECT InvoiceNo, Quantity, UnitPrice
FROM online_retail_dataset
WHERE Quantity <= 0 OR UnitPrice <= 0;
```

- Resultado esperado: una tabla vacía.

Análisis Modular

Procesamiento de Datos

Creación de Consulta Modulada

```sql
CREATE VIEW sales_insights AS
  SELECT InvoiceNo,
    Quantity,
    InvoiceDate,
    UnitPrice,
    Country,
    Discount,
    ShippingCost,
    Category,
    ShipmentProvider,
    WarehouseLocation,
    (UnitPrice * Quantity) * (1 - Discount) AS NetRevenue -- Ingreso por Ticket

  FROM sales
  WHERE ReturnStatus = 'Not Returned';
```

Análisis Estadístico

Indicadores Generales

```
SELECT SUM(NetRevenue) AS TotalRevenue,       -- Ingreso Neto Total
      COUNT(InvoiceNo) AS OrderVolume,        -- Cantidad de Ventas Realizadas
      ROUND(AVG(NetRevenue), 2) AS AvgSale    -- Ingreso Promedio por Ticket
FROM sales_insights;
```

Agrupación por Dimensiones

Por Categoría

```
SELECT Category, SUM(NetRevenue) AS TotalSales,
        COUNT(InvoiceNo) AS OrderVolume, SUM(Quantity) AS UnitsSold
FROM sales_insights
GROUP BY Category
ORDER BY TotalSales DESC;
```

Por País

```
SELECT Country, SUM(NetRevenue) AS TotalSales, COUNT(InvoiceNo) AS OrderVolume,
       ROUND(AVG(NetRevenue), 2) AS AvgSale
FROM sales_insights
GROUP BY Country
ORDER BY TotalSales DESC;
```

Análisis Temporal

```
SELECT YEAR(InvoiceDate) AS Year, Month(InvoiceDate) AS Month,
        SUM(NetRevenue) AS TotalSales, COUNT(InvoiceNo) AS OrderVolume
FROM sales_insights
GROUP BY Year, Month
ORDER BY TotalSales DESC;
```

Cálculo de Logística

```
SELECT WarehouseLocation, ShipmentProvider,
        COUNT(InvoiceNo) AS TotalOrders, ROUND(AVG(ShippingCost), 2) AS AvgCost
FROM sales_insights
GROUP BY WarehouseLocation, ShipmentProvider
ORDER BY AvgCost DESC,
```

Comunicación Estratégica

Visualización

Construcción del Dashboard

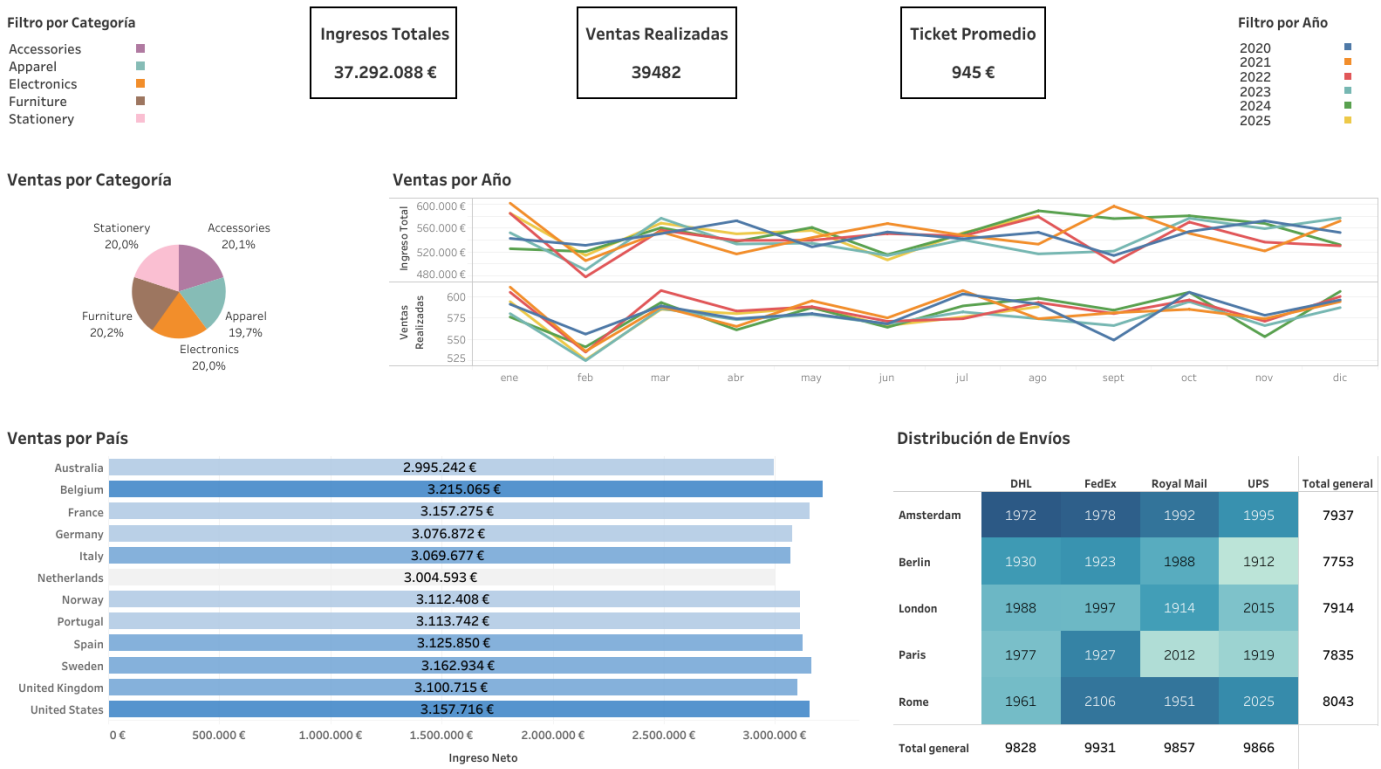

Storytelling

Implementación de Filtros Interactivos y Detalle en cada Agrupación

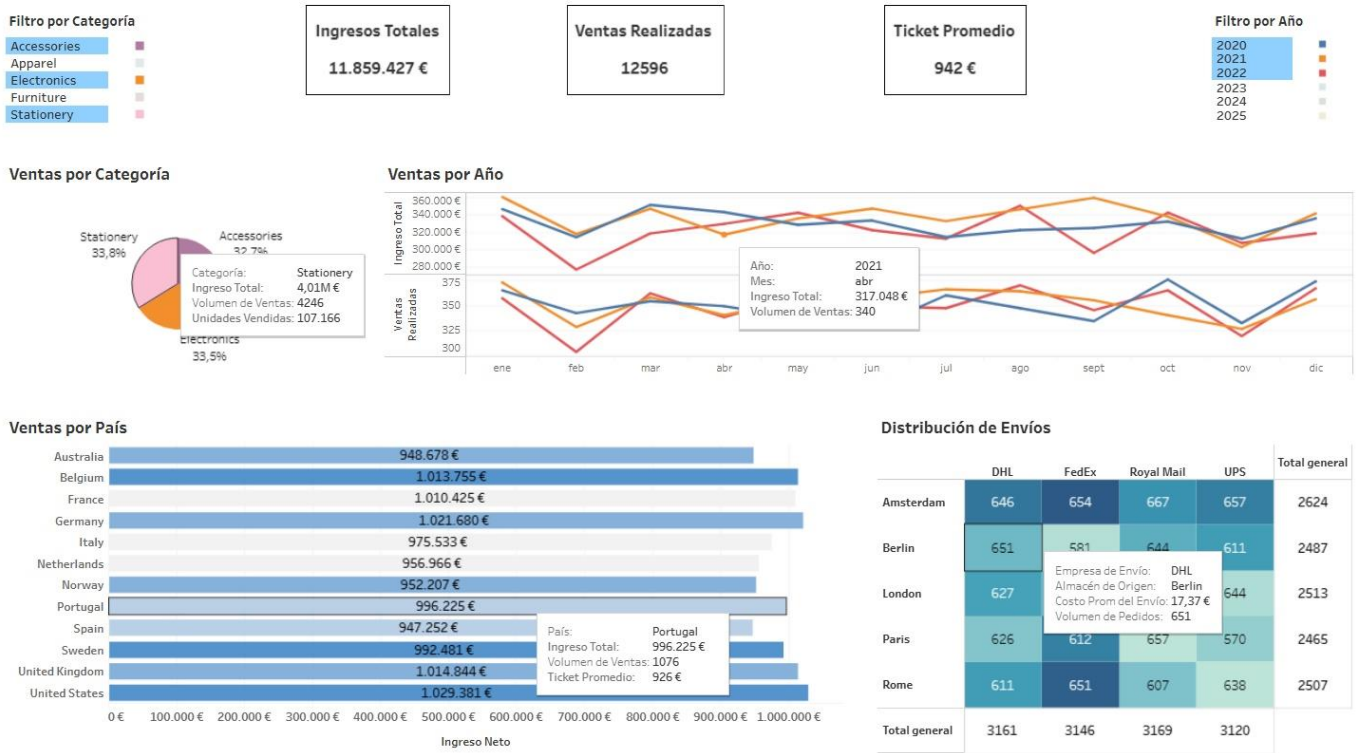

Monitoreo y Salud (Observabilidad)

Data Drift

Categórica

- **Estado Base**: Todas las categorías aportan **€ 7.4M** cada una en el ingreso total.
- **Escenario**: El próximo trimestre **Electronics** sube **€ 15M** mientras **Furniture** baja a **€ 2M**.
- **Impacto**: Variación de más de un umbral del 20%, detectar si se debe a una región en específico o aumentó la cantidad de devoluciones de determinado producto.

Conceptual

- **Estado Base:** El promedio por Ticket es de **€ 944,53**.
- **Escenario:** El **UnitPrice** se mantiene estable en todas las categorías pero el **AvgTicket** cae a **€ 400**.
- **Interpretación:** Cambio drástico del comportamiento del consumidor. Se puede deber a compran una menor cantidad de productos o sólo aquellos productos que se encuentren en descuento.

Geográfica

- **Estado Base:** El volumen de órdenes por país es estable, rondando las **3300 órdenes** por nación.
- **Escenario:** Cambio donde **Reino Unido** duplica su volumen de órdenes pero el volumen se mantiene igual en Europa.
- **Impacto**: Reconfiguración de Logística (Almacenes y Couriers), ya que el centro de ventas se desplazó geográficamente.

Operacional

- **Estado Base:** El promedio del costo por envío oscila entre los **€ 17,19** y **€ 17,78**.
- **Escenario:** Si debido a una escases de combustible el costo asciende a los y **€ 25**.
- **Acción:** El script de salud debería de disparar una alerta si el promedio excede el límite histórico de **€ 18,00**.

Auditoría

Categórica (Drift de Distribución)

```sql
SELECT
    Category,
    ROUND(SUM(NetRevenue), 2) AS Revenue_Actual,
    ROUND((SUM(NetRevenue) / 37292000) * 100, 2) AS Porcentaje_Participacion,
    CASE
        WHEN (SUM(NetRevenue) / 37292000) > 0.25 THEN 'ALERTA: Concentración Excesiva'
        WHEN (SUM(NetRevenue) / 37292000) < 0.15 THEN 'ALERTA: Caída de Interés'
        ELSE 'Distribución Estable'
    END AS Estado_Drift
FROM sales_insights
GROUP BY Category;
```

Conceptual (Ticket Promedio)

```sql
SELECT
    ROUND(AVG(NetRevenue), 2) AS AvgTicket_Actual,
    944.53 AS Baseline_Historico,
    ROUND(ABS(AVG(NetRevenue) - 944.53) / 944.53 * 100, 2) AS Porcentaje_Variacion,
    CASE
        WHEN ABS(AVG (NetRevenue) - 944.53) / 944.53 > 0.10
        THEN 'ALERTA: Cambio en Concepto de Gasto'
        ELSE 'Comportamiento Normal'
    END AS Status_Drift
FROM sales_insights;
```

Geográfica (Volumen Por País)

```sql
SELECT
    Country,
    COUNT(InvoiceNo) AS Volumen_Actual,
    3300 AS Media_Historica_Ordenes,
    CASE
        WHEN COUNT(InvoiceNo) > 4000 THEN 'ALERTA: Pico de Demanda Regional'
        WHEN COUNT(InvoiceNo) < 2500 THEN 'ALERTA: Deserción de Mercado'
        ELSE 'Demanda Estable'
    END AS Estado_Geografico
FROM sales_insights
GROUP BY Country;
```

Operacional (Costos Logísticos)

```sql
SELECT
    WarehouseLocation,
    ShipmentProvider,
    ROUND(AVG(ShippingCost), 2) AS Costo_Actual,
    17.78 AS Techo_Costo_Historico,
    CASE
        WHEN AVG(ShippingCost) > 17.78 * 1.05 THEN 'ALERTA: Incremento en Costos Logísticos'
        ELSE 'Costo Bajo Control'
    END AS Control_Costo
FROM sales_insights
GROUP BY WarehouseLocation, ShipmentProvider
ORDER BY Costo_Actual DESC, WarehouseLocation ASC;
```